

Costea Andrei Ioan - 315CA

F1 Lap Time Predictor

Acest proiect isi propune sa prezica timpul total pe tur (lap_duration) al unei masini de Formula 1, fara a cunoaste timpul pe ultimul sector. Datele cunoscute de model sunt: timpii pe primele doua sectoare, vitezele maxime pe linii drepte, tipul de anvelopa folosit si al catelea set de anvelopa. Modelul este dezvoltat in Python folosind algoritmul Random Forest Regressor, iar proiectul include si o interfata grafica interactiva realizata in Gradio.

Structura Proiectului

- train.csv / test.csv - Seturile de date extrase din telemetria oficiala
- data.py - Scriptul pentru extragerea, curatarea si completarea datelor
- eda.py - Scriptul pentru analiza datelor si generarea graficelor
- app.py - Scriptul principal care antreneaza modelul, afiseaza metricile de performanta si lanseaza interfata grafica Gradio
- README.pdf - Documentatia completa a proiectului

Extragerea, Curatarea si Completarea Datelor

Datele au fost extrase prin intermediul OpenF1 API, vizand mai multe sesiuni (antrenamente, calificari, cursa) pentru a asigura un volum mare si diversificat de informatii.

Pasii de procesare:

1. Preluarea datelor: Am facut request-uri separate catre endpoint-urile de laps (timpii pe tur) si stints (date despre pneuri si opriri la boxe)
2. Sincronizarea seturilor de date: Deoarece datele despre pneuri si timpii erau separate, s-a folosit functia `pd.merge_asof()` din

Pandas. Aceasta a permis o imbinare, mapand fiecare tur la tipul corect de pneu, in functie de numarul turului la care s-a inceput stintul respectiv

3. Maparea Pilotilor: API-ul furniza doar numarul masinii. Am creat un dictionare care asociaza numerele cu acronimele pilotilor
4. Tratarea valorilor lipsa: Randurile fara lap_duration sau stint_number au fost eliminate, fiind imposibil de folosit pentru antrenare. Valorile lipsa din coloanele numerice de telemetrie (duration_sector_1, duration_sector_2, duration_sector_3, i1_speed, i2_speed) au fost completate folosind media coloanei respective, pentru a nu pierde un volum mare de date si a pastra distributia intacta.
5. Impartirea datelor: Setul final a fost impartit in train.csv (70%, 1083 randuri) si test.csv (30%, 465 randuri)

Analiza Exploratorie a Datelor



Identificarea si tratarea valorilor lipsa

In urma rularii scriptului eda.py analiza arata un procentaj de 0% valori lipsa in ambele seturi. Aceasta integritate a fost obtinuta prin curatarea initiala din scriptul de colectare, cum am explicat mai sus.

Statistici descriptive si distributii

Analiza variabilelor categorice (compound si driver_name):

- Rezultate train: 1083 inregistrari, 20 de piloti unici, pneul cel mai frecvent este SOFT (frecventa: 557), iar cel mai activ pilot este Charles Leclerc (65 tururi)
- Rezultate test: 465 inregistrari, 20 piloti unici, pneul cel mai frecvent ramane SOFT (frecventa: 248), iar cel mai activ pilot este Fernando Alonso (31 de tururi)





Analiza variabilelor Numerice:

Graficele de mai jos reprezinta histograme pentru principalii indicatori de telemetrie (duration_sector_1, duration_sector_2, duration_sector_3, i1_speed, i2_speed). Axa OY masoara frecventa, iar axa OX corespunde valorilor specifice fiecarei variabile in parte.

- Interpretare timpi pe sectoare (S1, S2, S3): Analiza arata distributii asimetrice cu cozi lungi indreptate spre dreapta. Media pe S1 este aprox. 35.9s, pentru S2 aprox. 49.7s, pentru S3 aprox. 35.3s. Prezenta acestor "cozi" evidentiaza vizual momentele de incetinire fortata din timpul sesiunilor (piloti prinsi in trafic pe portiunile virajate, tururi de racire a pneurilor sau iesiri lente de la boxe).
- Interpretare viteze intermediare (i1_speed, i2_speed): Graficele pentru vitezele inregistrate la punctele de detectie

(i1 si i2) arata distributii multimodale, cu o concentrare masiva de date in zona superioara (250 - 300 km/h), reprezentand momentele in care masinile se afla in regim de simulare de calificari sau tururi rapide de cursa. Varfurile secundare din zona vitezelor mici (80 - 150 km/h) reflecta perioade de rulare lenta.







Analiza si Identificarea Outlierilor (Valorilor Extreme)

Analiza si rezultate:

- Train: Folosind regula IQR, s-a stabilit intervalul valid matematic pentru un tur normal ca fiind [16.597, 233.931 secunde]. S-au detectat 130 de outlieri. Timpul maxim brut a atins o valoare aberanta de 2247.68 secunde
- Test: Intervalul IQR este [14.718, 235.838 secunde], inregistrand 57 de outlieri, cu un maxim brut de 2380.57 secunde

Explicatia fenomenului:

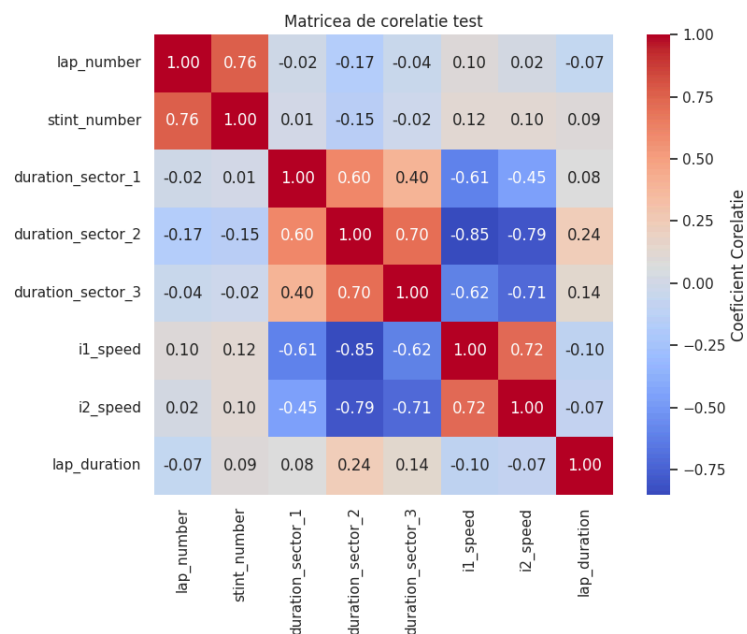

- Acesti outlieri nu sunt erori ale API-ului, ci au o semnificatie reala in motorsport: reprezinta tururile in care pilotii au intrat sau au iesit de la boxe (unde exista limitator de viteza), tururi rulate sub incidenta unui safety car, sau sesiuni intrerupte.



Corelatia caracteristicilor (Matricea de Corelatie)

Matricele extrase pun in evidenta legaturile stranse bazate pe fizica dinamica a unei masini de Formula 1

- Corelatia viteze vs sectoare: Exista o corelatie negativa puternica intre `duration_sector_2` si `i1_speed` (-0.83 in train, -0.85 in test), precum si cu `i2_speed` (-0.80). Semnul minus denota o proportionalitate inversa perfecta: pe masura ce viteza maxima la capatul liniilor drepte este mai ridicata, timpul in sector scade automat.





Relatia caracteristicilor cu variabila tinta

Studiul comportamentului caracteristicilor in raport cu timpul total pe tur scoate la iveala pilonul central al strategiei de eliminare a ultimului sector.

- Graficul arata o distributie punctiforma stransa sub forma de linie diagonala perfecta intre duration_sector_2 si lap_duration. Acest lucru demonstreaza vizual ca Sectorul 2 este cel mai bun predictor liniar global pentru dinamica circuitului respectiv. Daca masina

pierde timp in Sectorul 2, tendinta se va replica aproape sigur si in abordarea virajelor stranse din Sectorul 3.




Modelul de machine learning

Pentru a crea o aplicatie cu utilitate reala, Sectorul 3 a fost eliminat intentionat din variabilele de intrare (x_{train}). Astfel, modelul simuleaza functionarea algoritmilor de pe Pit Wall, unde estimarea trebuie facuta inainte ca pilotul sa finalizeze turul.

Am folosit un model de tip Random Forest Regressor, care a invatat sa coreleze primele doua sectoare, degradarea cauzata de numarul turului, tipul de pneu si vitezele intermediare, pentru a prezice lap_duration fara a sti timpul pe Sectorul 3.

Performantele obtinute pe setul curatat de outlieri:

- R-squared: 0.7433 - Modelul reuseste sa explice peste 74% din variatia timpului final, bazandu-se doar pe 66% din lungimea circuitului.
- RMSE: 2.72 secunde - O marja de eroare care capteaza imprevizibilitatea ultimului sector (ex.: trafic in ultimele viraje, degradare neasteptata a pneului). Pe tururile "curate", eroarea scade frecvent sub 0.2 secunde.



```
(rmse) > test_scores = cross_val_score(estimator, X_test, y_test, cv=5)
(Rmse) > print(test_scores.mean())
(Rmse) > print(test_scores.std())
```

R_squared (R2): 0.7433			
RMSE: 2.7267 secunde			
	Timp real (sec)	Timp Prezis (sec)	Eroare absoluta (sec)
0	95.928	96.144	0.216
1	99.687	99.736	0.049
2	91.421	91.637	0.216
3	99.624	100.490	0.866
4	92.310	92.163	0.147

Interfata grafica (Gradio)

Pentru a interactiona cu modelul, am implementat o interfata vizuala folosind biblioteca Gradio. Aceasta permite utilizatorului sa introduca datele de telemetrie partiala ale masinii:

- Stadiul uzurii: numar tur, numar stint
- Timpii si telemetrie partiala: sector 1, sector 2, viteza i1, viteza i2

- Mecanica: tipul de pneu (HARD, MEDIUM, SOFT)